

EJERCICIO DE PROGRAMACIÓN

Escenario 1

- Política elegida: per_class_f1
- Justificación
En detección de fraude la métrica global de accuracy es engañosa: si el 99 % de las transacciones son legítimas, un modelo que siempre predice no fraude tiene un 99 % de accuracy y es completamente inútil. El coste real viene de los falsos negativos (fraude que pasa sin detectarse). La métrica relevante es la F1-score de la clase fraude, que pondera tanto la precisión el recall. Un nuevo modelo solo debe activarse si mejora el F1. de

Escenario 2

- Política elegida: any_improvement
- Justificación
En sistemas de recomendación el peor caso es simplemente que el usuario vea una película que no le gusta tanto. El objetivo es maximizar la experiencia del usuario de forma continua y progresiva. Usar `>=` (el gate actual) ya cubre este escenario: si el nuevo modelo iguala o supera al anterior, lo activamos. No tiene sentido exigir una mejora mínima significativa porque estaríamos desechando mejoras reales pequeñas que, acumuladas en el tiempo, tienen impacto positivo.

Escenario 3

- Política elegida: min_delta
- Justificación
En un entorno clínico, un médico calibra su confianza en el sistema a lo largo del tiempo. Si el modelo cambia con cada reentrenamiento, aunque mejore marginalmente se generan problemas de confianza, auditoría y trazabilidad regulatoria. Además, las mejoras marginales en un conjunto de validación pequeño pueden ser ruido estadístico, no mejoras reales. Exigir un delta mínimo significativo antes de activar el nuevo modelo garantiza que solo aceptamos cambios con evidencia sólida de mejora, y que el comportamiento del sistema sea estable y predecible para los clínicos que lo usan. Un nuevo modelo que mejora un 0.1 % no justifica el riesgo del cambio en un contexto de consecuencias graves.