

Justificación del criterio de registro

En el contexto de diagnóstico de diabetes, los errores no tienen el mismo coste clínico.

Tipo de error	Consecuencia clínica	Gravedad
Falso Negativo	Enfermedad no tratada: retinopatía, nefropatía, amputaciones	ALTA
Falso Positivo	Ansiedad temporal + pruebas adicionales (HbA1c, OGTT)	Baja

Por ello, la métrica optimizada en el Grid Search es el Recall (Sensibilidad) y el criterio para incluir un modelo en el Model Registry es:

$$\text{Recall} \geq 0.70 \text{ y } \text{F1-score} \geq 0.65$$

El umbral de Recall garantiza que al menos el 70% de los pacientes diabéticos reales sean detectados, mientras que el umbral de F1-score evita modelos que predigan siempre positivo debido al desbalance del dataset.

Runs realizados y decisión de registro

Run	Modelo	Val Recall	Val F1	Accuracy	Precision	ROC-AUC	CV Recall	Registrado
GradientBoosting_best	GradientBoosting	0.8519	0.7966	0.8312	0.7419	0.8665	0.7262	SI
SVM_best	SVM	0.8704	0.7121	0.7532	0.5957	0.8481	0.7310	SI
RandomForest_best	RandomForest	0.8519	0.7731	0.8247	0.7097	0.8665	0.7262	SI
LogisticRegression_best	LogisticRegression	0.7963	0.7167	0.7792	0.6515	0.8481	0.7262	SI

Parámetros de los modelos registrados

GradientBoosting (modelo seleccionado)

Parámetro	Valor
model_type	GradientBoosting
n_estimators	100-200
max_depth	3-5
learning_rate	0.05-0.1
subsample	0.8-1.0
grid_search_scoring	recall
cv_folds	5
class_weight	balanced

Métricas de validación: Recall=0.8519, F1=0.7966, Accuracy=0.8312, ROC-AUC=0.8665

RandomForest

Parámetro	Valor
n_estimators	100-300
max_depth	None / 5 / 10
min_samples_split	2-5
min_samples_leaf	1-2
class_weight	balanced

Métricas: Recall=0.8519, F1=0.7731, Accuracy=0.8247, ROC-AUC=0.8665

LogisticRegression

Parámetro	Valor
C	0.01
penalty	l1
solver	saga
max_iter	500
class_weight	balanced

Métricas: Recall=0.7963, F1=0.7167, Accuracy=0.7792, ROC-AUC=0.8481

SVM

Parámetro	Valor
C	1.0-10.0
kernel	rbf
gamma	scale
class_weight	balanced
probability	True

Métricas: Recall=0.8704, F1=0.7121, Accuracy=0.7532, ROC-AUC=0.8481

Por qué se registran estos modelos

Todos los runs del experimento `diabetes_experimentos_completos` superaron el umbral de registro (Recall ≥ 0.70 y F1 ≥ 0.65). Por ello se incluyeron cuatro modelos en el Model Registry.

- **GradientBoosting:** mejor balance global entre recall, F1 y ROC-AUC. Seleccionado como modelo principal de producción.
- **RandomForest:** recall equivalente al de GradientBoosting con métricas equilibradas.
- **SVM:** mayor recall de todos los modelos (0.87), aunque con menor precisión.
- **LogisticRegression:** modelo más simple e interpretable, útil como baseline de producción.

Evaluación final en Test Set

Métricas

Métrica	Valor
Accuracy	0.7792 (77.9%)
Precision	0.6667 (66.7%)
Recall	0.7407 (74.1%)
F1 Score	0.7018 (70.2%)
Specificity	0.8000 (80.0%)
NPV	0.8511 (85.1%)

Matriz de confusión

	Pred: No Diabetes	Pred: Diabetes
Real: No Diabetes	TN = 40	FP = 10
Real: Diabetes	FN = 7	TP = 20

El modelo presenta un recall del 74.1%, lo que significa que detecta correctamente el 74.1% de los casos reales de diabetes. Sin embargo, se observan 7 falsos negativos, es decir, pacientes diabéticos que no fueron identificados por el modelo, lo que representa el mayor riesgo clínico. También se registran 10 falsos positivos, correspondientes a pacientes sanos diagnosticados erróneamente como diabéticos. Aunque estos casos pueden generar ansiedad y requerir pruebas médicas adicionales, su impacto es menos crítico que el de los falsos negativos.

Reporte de clasificación

	precision	recall	f1-score	support
No Diabetes	0.85	0.80	0.82	50
Diabetes	0.67	0.74	0.70	27
accuracy			0.78	77
macro avg	0.76	0.77	0.76	77
weighted avg	0.79	0.78	0.78	77

Conclusión

La evaluación sobre el test set real confirma el rendimiento generalizable del modelo seleccionado. El recall del 74.1% indica que el modelo detecta la mayoría de los pacientes con diabetes. Aunque existen falsos negativos, el rendimiento global muestra un equilibrio razonable entre sensibilidad y precisión, lo que lo hace adecuado para un escenario de cribado médico donde es prioritario detectar el mayor número posible de casos reales.